Hvala akademiku prof. dr. sc. Zvonimiru Šipušu na ugodnom mentorstvu, te obitelji na podršci.

Sadržaj

1. Uvod **3**

2. Skupljanje podataka **5**

2.1. Web scraper i prikupljanje podataka 5

2.2. Inicijalna faza i bot policy 6

2.3. Proširenje na puni dataset 6

2.4. Statistički opis dataseta 7

2.5. Ograničenja izvora podataka 8

3. Priprema podataka **9**

3.1. Čišćenje podataka 9

3.2. Imputacija i sentinel varijable 10

3.3. Inženjering značajki 11

3.3.1. Log transformacija ciljne varijable 11

3.3.2. Izvedene numeričke značajke 11

3.3.3. Veličinska kategorija 12

3.3.4. Binarne značajke 12

3.3.5. Interakcijske značajke 12

3.3.6. Lokacijske značajke 13

4. Modeliranje **14**

4.1. Ridge regresija kao baseline model 14

4.2. Boosting modeli i stacking 15

5. Rezultati i evaluacija **18**

5.1. Performanse modela 18

5.2. Važnost značajki 19
5.3. Klasifikacija GREEN/YELLOW/RED 20
5.4. Vanjska validacija 21

6. Zaključak 24

Literatura 26

7. Sažetak 27

8. Abstract 28

1. Uvod

Tržište nekretnina jedno je od ekonomski najznačajnijih segmenata svake nacionalne ekonomije, a procjena vrijednosti nekretnine ključna je informacija kako za kupce i prodavače tako i za financijske institucije i investitore. Unatoč tome, pristup objektivnoj i transparentnoj procjeni vrijednosti nekretnine u Hrvatskoj tradicionalno je ograničen — potencijalni kupci najčešće se oslanjaju na subjektivnu procjenu agenta ili vlastitu intuiciju temeljenu na pregledavanju oglasa, bez mogućnosti sistematske usporedbe s tržišnom vrijednošću.

Hedonički pricing model pristup je vrednovanju koji cijenu nekretnine tretira kao zbroj implicitnih vrijednosti njezinih zasebnih karakteristika — kvadrature, lokacije, kata, energetskog razreda, dostupnosti lifta i brojnih drugih. Takav pristup omogućuje izgradnju prediktivnog modela koji procjenjuje fer tržišnu vrijednost nekretnine na temelju njezinih mjerljivih karakteristika, neovisno o subjektivnoj procjeni prodavača.

Cilj ovog rada je razvoj sustava koji automatski prikuplja podatke o oglašenim stanovima na području Zagreba, gradi hedonički pricing model te klasificira oglase prema odstupanju oglašene cijene od modelom procijenjene fer vrijednosti. Sustav je zamišljen kao alat koji kupcu nekretnine omogućuje donošenje informiranijih odluka temeljenih na objektivnoj analizi tržišnih podataka.

Slika 1.1. Pipeline sustava za analizu cijena nekretnina

Za prikupljanje podataka razvijen je web scraper koji automatski dohvaća oglase s portala Njuškalo.hr, najpopularnije hrvatske platforme za kupoprodaju nekretnina. Na prikupljenom skupu od 7 174 stanova treniran je ansambl modela strojnog učenja koji kombinira CatBoost, XGBoost i LightGBM algoritme kroz stacking arhitekturu, posti-

žući koeficijent determinacije $R^2 = 0{,}903$ na test skupu. Sustav je validiran usporedbom s komercijalnim alatom za procjenu nekretnina, što je omogućilo identifikaciju ključnih ograničenja i smjerova budućeg razvoja.

Rad je organiziran na sljedeći način. Poglavlje 2. opisuje proces prikupljanja podataka, uključujući implementaciju web scrapera i probleme koji su se pri tome pojavili. Poglavlje 3. opisuje pripremu podataka — čišćenje, imputaciju i inženjering značajki. Poglavlje 4. opisuje korištene modele strojnog učenja i stacking arhitekturu. Poglavlje 5. prikazuje rezultate, analizu važnosti značajki, klasifikaciju oglasa i vanjsku validaciju modela. Poglavlje 6. donosi zaključke i prijedloge za budući razvoj.

2. Skupljanje podataka

2.1. Web scraper i prikupljanje podataka

Hedonički model procjene vrijednosti nekretnine zasniva se na ukupnosti procjena zasebnih karakteristika koje opisuju tu nekretninu. Stoga je prvi i neophodan korak bio prikupljanje dovoljno velikog i kvalitetnog skupa podataka koji sadrži te karakteristike.

Podatke smo prikupljali s Njuškalo.hr, najpopularnije hrvatske platforme za kupoprodaju nekretnina [1]. Za tu svrhu razvijen je web scraper temeljen na Selenium biblioteci, budući da Njuškalo dinamički renderira sadržaj stranice putem JavaScripta — klasični HTTP scraper temeljen na *requests* biblioteci ne bi mogao dohvatiti podatke jer bi čitao HTML prije nego što je DOM potpuno učitan.

Prije implementacije scrapera, ručnom inspekcijom HTML strukture stranice oglasa u preglednikovim razvojnim alatima identificirane su ključne CSS klase koje sadrže podatke o nekretnini — `ClassifiedDetailBasicDetails-list` za tablicu karakteristika, `ClassifiedDetailHighlightedAttributes` za istaknute podatke poput kvadrature i broja soba, te `ClassifiedDetailPropertyGroups` za grupirane karakteristike poput grijanja i funkcionalnosti. Na temelju te analize projektiran je parser koji dinamički prati sve prisutne kategorije.

Oglasi su strukturirani od slike, opisa te tablice s karakteristikama nekretnine. Upravo ta tablica pokazala se najpraktičnijim i najpouzdanijim izvorom strukturiranih podataka. No već pri ručnom pregledu manjeg broja oglasa uočena je značajna nekonzistentnost — oglasi nemaju uniformno popunjene sve kategorije. Dok su osnovne kategorije poput kvadrature, broja soba i cijene zastupljene u većini oglasa, zastupljenost kategorija kao što su energetski razred, godina renovacije, orijentacija stana i parking znatno opada. Stoga je logika scrapera implementirana tako da pri svakom čitanju oglasa dina-

mički evidentira sve prisutne kategorije, proširuje listu praćenih kategorija pri nailasku na novu te bilježi prisutnost svake kategorije za svaki oglas zasebno.

2.2. Inicijalna faza i bot policy

U ranoj fazi razvoja prikupljeno je svega ∼400 oglasa — tek dovoljno da se provjeri može li se i najjednostavnijim regresijskim modelima izvući ikakav signal. Tek nakon što je potvrđena smislenost pristupa opravdano je ulaganje vremena u prikupljanje većeg skupa podataka i razvoj složenijih modela.

Već pri tom inicijalnom prikupljanju bilo je potrebno doskočiti Njuškalovoj antibot politici. Cilj je bio izbjeći privremenu blokadu IP adrese koja nastaje kao posljedica prevelikog broja HTTP zahtjeva u kratkom roku u uzorku koji ne nalikuje ljudskom pretraživanju. Primijenjene su dvije mjere: pseudonasumični razmaci između zahtjeva u rasponu od 0,8 do 1,5 sekundi te rotacija User-Agent zaglavlja kojima scraper simulira različite preglednike i operacijske sustave. Zahvaljujući tim mjerama prikupljanje inicijalnih ∼400 oglasa odvijalo se bez prekida, no trajalo je otprilike 5 sati.

2.3. Proširenje na puni dataset

Nakon potvrde smislenosti pristupa, cilj je bio prikupiti sve oglase nekretnina na Njuškalu za zagrebačko područje — procijenjeno na oko 7 200 oglasa. Budući da je to dugotrajan proces podložan raznim prekidima, u scraper je uveden checkpoint sustav koji periodički sprema napredak obrade. U slučaju prekida zbog nestanka mreže, baterije ili privremene suspenzije, proces se nastavlja od zadnje pohranjena točke umjesto ispočetka.

Taj checkpoint mehanizam pokazao se itekako korisnim jer je prikupljanje naišlo na niz problema. Prvi pokušaj ubrzanja procesa rezultirao je time da oko 90% prikupljenih oglasa nije imalo cijenu — ključnu varijablu bez koje oglas nije upotrebljiv. Uzrok je bila prevelika brzina čitanja: scraper je čitao DOM prije nego što je JavaScript stigao isporučiti podatke na frontend. Problem je riješen uvođenjem eksplicitnog čekanja putem `WebDriverWait` mehanizma koji pauzira izvođenje sve dok se ciljni elementi ne pojave u DOM-u.

Nakon ponovnog pokretanja, Njuškalo je detektirao scraping aktivnost i prikazao CAPTCHA provjeru koju automatski scraper nije mogao zaobići, što je rezultiralo privremenom suspenznijom. Povećanjem trajanja pauza između zahtjeva idući pokušaj bio je uspješan. Prikupljanje svih oglasa trajalo je nešto više od 48 sati.

Slika 2.1. Dijagram toka — Njuškalo Scraper v2

Ukupno je prikupljeno nešto više od 10 000 oglasa, što je više od stvarnog broja aktivnih oglasa zbog toga što scraper nije precizno detektirao kraj stranica s paginacijom već je obradio unaprijed definirani broj stranica koji je postavljen konzervativno kako bi se osiguralo da nijedan oglas ne bude izostavljen. Nakon uklanjanja duplikata na temelju jedinstvenog identifikatora oglasa, skup je sveden na 7 696 jedinstvenih oglasa koji su korišteni u daljnjoj analizi.

2.4. Statistički opis dataseta

Nakon prikupljanja i uklanjanja duplikata, finalni skup podataka sadrži 7 696 redaka koji predstavljaju jedinstvene oglase stanova na području Zagreba te neuniformno popunjenih 58 stupaca koji predstavljaju njihove karakteristike.

Slika 2.2. Zastupljenost kategorija u sirovim oglasima (7 696 jedinstvenih oglasa, Njuškalo.hr)

Vidljivo je da su osnovne karakteristike poput broja soba, kvadrature i cijene zastupljene u gotovo svim oglasima, dok kategorije poput energetskog razreda (35,1%) i neto površine (19,8%) nedostaju u većini oglasa. Ta neravnomjerna popunjenost zahtijevala je poseban pristup pri pripremi podataka, opisan u sljedećem poglavlju.

Raspon cijena kreće se od 52 001 € do 1 950 000 €, s medianom od 299 032 € i prosječnom cijenom od 364 230 €. Značajna razlika između medijana i prosjeka ukazuje na prisutnost skupih outliera koji povlače prosjek prema gore — što je karakteristično za tržišta nekretnina gdje manji broj luksuznih nekretnina značajno utječe na srednju vrijednost. Standardna devijacija od 219 875 € potvrđuje visoku varijabilnost cijena, što je i očekivano s obzirom na heterogenost zagrebačkih kvartova i tipova nekretnina.

Slika 2.3. Distribucija cijena stanova po gradskim četvrtima Zagreba (medijan, Q1–Q3, min–max)

Vidljivo je da su Podsljeme, Maksimir i Gornji Grad – Medveščak najskuplji kvartovi s najvećim rasipanjem cijena, dok su Sesvete, Novi Zagreb i Donja Dubrava najjeftiniji i najhomogeniji. Posebno je zanimljivo da široki raspon cijena unutar pojedinih kvartova, kao što su Donji Grad i Gornji Grad, ukazuje na limitiranost kvarta kao jedine lokacijske varijable u modelu.

2.5. Ograničenja izvora podataka

Valja biti svjestan ograničenja i pouzdanosti izvora podataka nad kojima ciljamo izvući zaključke. Općepoznato je da oglašena cijena ne odražava nužno stvarnu prodajnu cijenu nekretnine — razlika često iznosi i do 15–20%, što inherentno utječe na kvalitetu modela koji se temelji isključivo na oglašenim cijenama.

Osim toga, oglasi su podložni subjektivnosti svojih autora, koja može biti posljedica nestručnosti ili svjesne želje za prikazivanjem nekretnine boljom nego što ona stvarno jest. To se najviše odražava na kategorizaciji stanja stana, kvalitete renovacije i gradnje — varijabli koje su ključne za procjenu vrijednosti, a koje naš model može pratiti samo kroz diskretne binarne oznake preuzete iz oglasa.

Dodatno, vlasnici nekretnina skloni su radi atraktivnosti oglasa u kategoriju kvadrature navesti bruto umjesto neto kvadrature, dok neto vrijednost tek napominju u tekstualnom opisu oglasa kojeg naš scraper ne obrađuje. Taj problem identificiran je tek nakon vanjske validacije modela s komercijalnim alatom, o čemu će detaljnije biti riječi u odgovarajućem poglavlju. Ta se činjenica pokazala kao najznačajnije ograničenje za daljnji razvoj prema komercijalno primjenjivom sustavu procjene vrijednosti nekretnina.

3. Priprema podataka

3.1. Čišćenje podataka

Jednom kada smo imali potpuni skup podataka, sirove podatke trebalo je prilagoditi kako bi bili što pogodniji za modele koji će iz njih učiti zaključivati vrijednost nekretnine.

Prvi korak bilo je uklanjanje duplikata na temelju jedinstvenog identifikatora oglasa, čime je skup sveden s 10 050 na 7 696 jedinstvenih oglasa.

Zatim su uklonjeni oglasi čije su karakteristike toliko udaljene od ostatka skupa da je najrazumnije pretpostaviti kako se radi o grešci ili o nekretnini koja nije stambena. Takvi uljezi najčešće su bili oglasi s iznimno nerazmjernom cijenom spram kvadrature, ali i čestice koje uopće nisu stanovi — pogrešno oglašena građevinska zemljišta i poslovni prostori koji su se zabunom našli na oglašeniku s kojeg smo prikupljali podatke. Sumnjivi oglasi identificirani su primjenom fiksnih minimalnih i maksimalnih pragova: izbačeni su stanovi s cijenom ispod 30 000 € i iznad 2 000 000 €, kvadraturom ispod 15 m^2 i iznad 500 m^2, te cijenom po m^2 ispod 1 000 € i iznad 10 000 €. Nakon tog koraka skup je sveden na 7 174 valjana oglasa.

Budući da Njuškalo koristi strukturirane tekstualne oznake za unos karakteristika nekretnine, numeričke značajke koje modeli zahtijevaju ekstrahirane su parsiranjem tih oznaka regularnim izrazima. Na primjer, broj soba ekstrahiran je iz oznaka poput `'3-sobni'` → 3 ili `'Garsonijera'` → 1, kvadratura pretvaranjem `'96,67 m²'` → 96,67, a kat mapiranjem tekstualnih opisa na cijele brojeve: `'Prizemlje'` → 0, `'Suteren'` → −1. Poseban slučaj bio je `'Potkrovlje'` koje nije moguće izraziti brojem kata — o načinu na koji smo ga tretirali više u sljedećem potpoglavlju.

3.2. Imputacija i sentinel varijable

Gotovo sve kategorije osim nekoliko najosnovnijih nisu popunjene u svim oglasima, što je vidljivo iz dijagrama zastupljenosti kategorija u prethodnom poglavlju. Konkretno, najkritičnija situacija je kod energetskog razreda gdje čak 64,9% oglasa nije imalo tu vrijednost, te kod godine renovacije koja nedostaje u 76,8% oglasa. Budući da modeli strojnog učenja ne mogu raditi s praznim vrijednostima, a izbacivanje svih nepotpunih oglasa drastično bi smanjilo veličinu skupa podataka, primijenili smo imputaciju medijanom — nedostajuće vrijednosti zamijenjene su medijanom te kategorije izračunatim iz oglasa koji ju imaju. Medijan je odabran umjesto prosjeka zbog robusnosti na outliere. Imputirane su sljedeće varijable: energetski razred, godina izgradnje, kat i godine od renovacije.

Za kategorije s jasnom pretpostavljenom vrijednošću pri izostanku podatka primijenjena je fiksna imputacija — broj kupaonica imputiran je vrijednošću 1 jer gotovo svaki stan ima barem jednu, a broj parkirnih mjesta vrijednošću 0 jer odsutnost podatka najčešće znači da parking nije dostupan. Za ukupni broj katova primijenjena je lokacijska imputacija — medijan unutar iste lokacije, uz globalni medijan kao fallback koji u praksi nikada nije bio potreban budući da svaka lokacija ima dovoljno oglasa s poznatim brojem katova.

Sama imputacija medijanom nije dovoljna jer model ne može razlikovati stan koji stvarno ima medijanski energetski razred od stana kojemu energetski razred nedostaje pa je pretpostavljen. Stoga smo uz imputaciju uveli sentinel varijable — binarne značajke koje bilježe je li vrijednost određene kategorije stvarno postojala u oglasu ili je bila imputirana. To modelu omogućuje da prilikom učenja smanji težinu veze između određene kategorije i cijene nekretnine u slučajevima kada je vrijednost imputirana, čime se zadržava kvaliteta učenja. Konkretne sentinel varijable su `energy_unknown` i `never_renovated`.

Poseban slučaj je varijabla `is_attic`. Pri pretvaranju kategorije kata iz tekstualnih oznaka u cijele brojeve, potkrovlju je privremeno dodijeljena vrijednost 99 kako bi se razlikovalo od stvarnih katova, a zatim zamijenjeno medijanom. Kako model ne bi pogrešno zaključio da se radi o devedesetdevetom katu, uvedena je binarna značajka `is_attic =`

1 koja modelu govori da je stan u potkrovlju. Za razliku od pravih sentinel varijabli koje bilježe odsutnost podatka, `is_attic` bilježi posebno stanje koje nije moguće izraziti brojem — no princip zaštite modela od pogrešne interpretacije je isti.

3.3. Inženjering značajki

Sirove kategorije iz oglasa same po sebi nisu dovoljne za kvalitetno modeliranje — iz njih je potrebno izvući i konstruirati značajke koje bolje opisuju vrijednost nekretnine. Inženjering značajki je proces kojim od dostupnih sirovih podataka gradimo bogatiji skup ulaznih varijabli za model.

3.3.1. Log transformacija ciljne varijable

Distribucija cijena stanova inherentno je desno asimetrična — većina stanova nalazi se u rasponu 100 000–500 000 €, dok manji broj luksuznih nekretnina doseže i do 2 000 000 €. Takva distribucija otežava učenje modela jer model pokušava minimizirati apsolutnu grešku, pa luksuzni stanovi s velikim apsolutnim vrijednostima neproporcionalno utječu na rezultat. Logaritmiranjem ciljne varijable distribucija se normalizira, a model uči relativne razlike umjesto apsolutnih — što je ekonomski ispravnije jer je razlika između 100 000 € i 200 000 € ekonomski ekvivalentna razlici između 500 000 € i 1 000 000 €. Iz istog razloga logaritmirana je i kvadratura (`log_m2`) kao jedna od najutjecajnijih ulaznih značajki.

3.3.2. Izvedene numeričke značajke

Iz dostupnih sirovih kategorija izvedeno je nekoliko numeričkih značajki koje bolje opisuju karakteristike nekretnine nego sirove vrijednosti. `building_age` izračunata je kao razlika između trenutne godine i godine izgradnje. Posebno zanimljiva je `effective_age` — efektivna starost zgrade definirana kao minimum između starosti zgrade i godina od zadnje renovacije. Ova značajka bolje opisuje stvarno stanje nekretnine jer renoviran star stan funkcionalno nije isti kao nerenoviran — stan iz 1970. koji je renoviran 2020. ima efektivnu starost od svega 6 godina. `floor_ratio` izračunata je kao omjer kata i ukupnog broja katova, što modelu daje relativnu poziciju stana u zgradi neovisno o apsolutnom broju katova. `rooms_per_m2` i `m2_per_room` opisuju prostornost stana — eks-

tremne vrijednosti ovih omjera mogu ukazivati na neobičan tlocrt.

3.3.3. Veličinska kategorija

Uvedene su tri binarne značajke koje kategoriziraju stan prema veličini: `is_small` za stanove ispod 55 m^2, `is_medium` za stanove između 45 m^2 i 100 m^2, te `is_large` za stanove iznad 85 m^2. Kategorije su namjerno definirane s preklapanjem — stan od 90 m^2 istovremeno je i srednji i veliki, što modelu daje više informacija o tome da se radi o graničnom slučaju.

3.3.4. Binarne značajke

Iz tekstualnih kategorija oglasa ekstrahirano je 28 binarnih značajki koje bilježe prisutnost ili odsutnost određene karakteristike nekretnine. Pokrivene su sljedeće kategorije: oprema (lift, klima, podno grijanje, električne rolete, alarm, video portafon, protuprovalna vrata), grijanje (plinsko, dizalica topline, centralno), vanjski prostori (balkon, lođa, terasa, vrt, bazen, spremište, garaža), dozvole (vlasnički list, građevinska i uporabna dozvola), namještenost i stanje te orijentacija stana.

3.3.5. Interakcijske značajke

Neke značajke tek u kombinaciji nose smislen signal za procjenu vrijednosti. Iz tog razloga uvedeno je 10 interakcijskih značajki. `floor_x_lift` kombinira kat i prisutnost lifta — visoki kat bez lifta značajno umanjuje vrijednost stana, dok visoki kat s liftom može biti prednost. `high_floor_no_lift` i `bad_floor_access` eksplicitno bilježe upravo taj negativni slučaj. `top_floor_terrace` hvata penthouse efekt — stan na zadnjem katu s terasom vrijedi značajno više nego zbroj tih dviju karakteristika zasebno. `old_not_renovated` kombinira starost zgrade i godine od renovacije kako bi identificirao stare nerenovirane stanove. `new_building_energy` kombinira novogradnju i energetski razred jer novogradnje gotovo uvijek imaju visoki energetski razred pa ta kombinacija nosi poseban signal.

3.3.6. Lokacijske značajke

Za svaki kvart uvedena je binarna dummy varijabla, ukupno 17 dummy varijabli za 17 zagrebačkih četvrti. Dummy varijable odabrane su umjesto jedne numeričke kolumne jer model ne bi smio pretpostavljati linearni redosljed između kvartova — Maksimir nije "dvostruko više" od Trešnjevke u nekom smislenom redoslijedu.

Uz dummy varijable uvedena je i numerička značajka `district_median_price_per_m2` — medijan cijene po m² unutar svakog kvarta izračunat iz samog dataseta. Ova značajka hvata lokacijski signal koji dummy varijable same ne mogu — model kroz nju direktno dobiva informaciju o prosječnoj razini cijena u kvartu, što se pokazalo kao druga najvažnija značajka u modelu iza kvadrature.

Slika 3.1. Korelacijska matrica ključnih značajki (Pearsonov koeficijent)

Korelacijska matrica potvrđuje očekivane veze između značajki — kvadratura i broj soba visoko su korelirani (0,71) što je prirodno jer veći stanovi imaju više soba. Godina izgradnje i starost zgrade pokazuju savršenu negativnu korelaciju (−1,00) jer su matematički izvedene jedna iz druge, što je očekivano. Zanimljivo je da medijan cijene po m² po kvartu pokazuje relativno skromnu korelaciju s cijenom (0,32), što potvrđuje ranije zaključke o limitiranosti kvarta kao lokacijske varijable — unutar istog kvarta postoje značajne razlike u cijeni koje ovaj signal ne hvata.

4. Modeliranje

4.1. Ridge regresija kao baseline model

Regresijski modeli statistička su i strojno-učena klasa modela namijenjena predviđanju numeričke vrijednosti na temelju jedne ili više ulaznih varijabli. Upravo takav tip modela nametnuo se kao prirodno rješenje problema predviđanja cijene nekretnine opisane skupom zasebnih karakteristika.

Iako postoje složeniji modeli koji konzistentno postižu bolje rezultate na problemima ovog tipa, najprije smo posegnuli za najjednostavnijim kako bismo potvrdili da skup podataka uopće nosi dovoljan signal za smisleno predviđanje. U tu svrhu korištena je regresija s L2 regularizacijom, poznata i kao Ridge regresija [2], kao ishodišni model.

Linearni regresijski modeli uče težinu za svaku značajku minimizirajući razliku između predviđene i stvarne vrijednosti. Kada regularizacija nije prisutna, a model se oslanja na velik broj međusobno koreliranih značajki — kakav je slučaj u našem datasetu gdje su npr. kvadratura i broj soba visoko korelirani — model može pojedinim značajkama dodijeliti iznimno velike težine a drugima zanemarive, što dovodi do overfittinga: preciznih predviđanja na podacima viđenim pri treniranju, ali slabije generalizacije na novim primjerima.

Regularizacija rješava taj problem dodavanjem kaznenog članka u funkciju greške koji raste s veličinom težina, prisiljavajući model da pronađe rješenje s umjerenijim težinama koje bolje generaliziraju:

$$\mathcal{L} = \sum_i (\hat{y}_i - y_i)^2 + \alpha \sum_j w_j^2 \tag{4.1}$$

Parametar α kontrolira jačinu kazne — veći α znači jaču regularizaciju i konzervativnije težine, manji α znači da se model više oslanja na podatke. Za razliku od L1 regularizacije (Lasso) koja može potpuno isključiti pojedine značajke postavljajući im težinu na nulu, L2 sve težine smanjuje ali ih ne eliminira — što je pogodnije u situaciji gdje sve značajke potencijalno nose korisnu informaciju o cijeni nekretnine.

Korištenjem Ridge regresije na inicijalnom manjem skupu podataka od 462 oglasa ostvaren je koeficijent determinacije $R^2 = 0{,}713$, što je bio jasan signal da skup podataka nosi dovoljan signal za predviđanje i da je opravdano problem proširiti na veći skup podataka i složenije modele.

Nakon što je potvrđena smislenost pristupa, skup podataka proširen je na 7 174 oglasa te je Ridge regresija uz napredne modele opisane u sljedećem potpoglavlju trenirana i na punom skupu kako bi služila kao referentna točka za usporedbu.

4.2. Boosting modeli i stacking

Rezultati regresijskog modela bili su nam dovoljni da se uvjerimo da nad skupljenim podacima možemo opravdano raditi predviđanja, no linearna priroda modela predstavlja ograničenje za kvalitetno predviđanje vrijednosti nekretnine. Veza između značajki i cijene nije linearna — npr. kvadratura ne utječe proporcionalno na cijenu za sve raspone veličina, a kombinacije značajki poput visokog kata s liftom nose drugačiji signal nego visoki kat bez lifta. Za modeliranje takvih nelinearnih odnosa boosting modeli su puno prikladniji od linearnih.

Boosting je metoda u kojoj se niz slabih modela, najčešće plitkih stabala odlučivanja, gradi iterativno pri čemu svaki sljedeći model uči na pogreškama prethodnih kako bi postupno poboljšao ukupnu točnost predviđanja. Za razliku od linearnih modela koji traže jedan najprikladniji pravac za opisati sve slučajeve, boosting modeli grade kompleksnu nelinearnu funkciju koja se prilagođava specifičnostima podataka.

Od mnoštva boosting algoritama odabrali smo tri koja su među najpopularnijim standardima za regresijske probleme ove kategorije — XGBoost [3], LightGBM [4] i CatBoost [5]. Međusobno se razlikuju pristupom gradijentnom boostingu, regularizaciji i brzini izvođenja.

XGBoost (eXtreme Gradient Boosting) uveo je niz tehničkih poboljšanja u odnosu na klasični gradient boosting, uključujući regularizaciju ugrađenu u funkciju cilja, paralelizaciju izgradnje stabala te učinkovito rukovanje nedostajućim vrijednostima. Zahvaljujući tim svojstvima postao je jedan od najpopularnijih algoritama za tablične podatke i de facto standard u natjecanjima iz strojnog učenja.

LightGBM (Light Gradient Boosting Machine) razvijen je s naglaskom na brzinu izvođenja i učinkovito korištenje memorije. Koristi histogramski algoritam za pronalaženje optimalnih točaka grananja te strategiju rasta stabla po listovima (leaf-wise growth) umjesto po razinama (level-wise growth), što omogućuje brže treniranje uz performanse usporedive s XGBoostom.

CatBoost (Categorical Boosting), razvijen u tvrtki Yandex, posebno je usmjeren na rad s kategoričkim varijablama te smanjenje preprilagođavanja (overfittinga). Koristi ordered boosting, tehniku kojom se sprječava korištenje informacija iz primjera koji se trenutno evaluira tijekom treniranja, čime se smanjuje pristranost modela i poboljšava generalizacija.

Budući da svaki od navedenih modela u praksi griješi na različitim primjerima, prirodno se nametnula ideja njihovog kombiniranja kroz stacking. Stacking je metoda ansambla u kojoj predikcije više modela prvog nivoa služe kao ulazne značajke modelu drugog nivoa koji uči kako ih optimalno kombinirati.

Konkretan izazov pri implementaciji stackinga je sljedeći: ako Ridge meta-model uči kombinirati predikcije na istim podacima na kojima su trenirani boosting modeli, ti modeli će na tim podacima imati artificijalno dobre predikcije jer su ih "vidjeli" pri treniranju. Meta-model bi tada naučio pogrešnu kombinaciju koja ne generalizira na nove podatke. Problem se rješava out-of-fold predikcijama — skup za treniranje dijeli se na 5 jednakih dijelova, svaki boosting model trenira se na 4 dijela i predviđa peti, te se rotira dok svaki primjer ne dobije predikciju od modela koji ga nije vidio. Ridge meta-model zatim uči kombinirati te nepristrane predikcije.

Slika 4.1. Stacking s out-of-fold predikcijama (5-fold)

Skup podataka podijeljen je u omjeru 80/20 — 5 739 stanova korišteno je za treniranje

modela, a preostalih 1 435 rezervirano je kao test skup koji modeli nisu vidjeli pri treniranju. Evaluacija na test skupu daje nepristranu procjenu stvarnih performansi modela na novim primjerima.

Hiperparametri svakog od tri boosting modela optimizirani su Optuna bibliotekom [6] korištenjem Bayesove optimizacije kroz 100 pokušaja po modelu uz 3-fold unakrsnu validaciju unutar svakog pokušaja. Rezultirajući optimalni parametri za XGBoost bili su `n_estimators=2434` i `learning_rate=0.015`, za LightGBM `num_leaves=62` i `learning_rate=0.011`, a za CatBoost `iterations=2679` i `learning_rate=0.047`. Ti parametri korišteni su u finalnom treniranju.

5. Rezultati i evaluacija

5.1. Performanse modela

Evaluacija modela provedena je na test skupu od 1 435 stanova koji nisu bili viđeni pri treniranju, što osigurava nepristranu procjenu stvarnih performansi sustava na novim primjerima.

Tablica 5.1. Usporedba performansi modela na test skupu (1 435 stanova)

Model	R^2	**MAE**	**RMSE**	**MAPE**
Ridge (baseline)	0,827	60 445 €	101 770 €	16,6%
CatBoost	0,901	42 207 €	73 220 €	11,7%
XGBoost	0,902	40 954 €	72 395 €	11,4%
LightGBM	0,901	41 654 €	73 793 €	11,5%
Stacking (finalni)	**0,903**	**40 929 €**	**73 397 €**	**11,3%**

Napredak od Ridge baseline modela do finalnog stacking modela je značajan — koeficijent determinacije porastao je s 0,827 na 0,903, što znači da model sada objašnjava 90% varijacije u cijenama stanova umjesto 83%. Prosječna relativna greška pala je s 16,6% na 11,3%, a apsolutna srednja greška s 60 445 € na 40 929 € — što praktično znači da model na stanu vrijednom 300 000 € prosječno griješi za oko 34 000 €.

Sva tri boosting modela postižu gotovo identične rezultate — CatBoost $R^2 = 0{,}901$, XGBoost $R^2 = 0{,}902$, LightGBM $R^2 = 0{,}901$. Ta ujednačenost nije slučajna već pozitivan signal — tri neovisno razvijena algoritma dolaze do istog zaključka, što potvrđuje robustnost pristupa i sugerira da je dosegnut praktični maksimum prediktivne moći dostupnih podataka.

Stacking model marginalno nadmašuje individualne boosting modele ($R^2 = 0{,}903$ vs. $\approx 0{,}901$) što je manji napredak nego što bi se moglo očekivati. Razlog leži u tome što su sva tri modela boosting algoritmi koji griješe na sličnim primjerima — stacking donosi najveću korist kad su kombinirani modeli međusobno različiti i komplementarni u svojim greškama.

Slika 5.1. Usporedba performansi modela (R^2 na test skupu)

5.2. Važnost značajki

Kako bi se razumjelo što model koristi pri procjeni vrijednosti nekretnine, analizirana je važnost značajki CatBoost modela — mjera koja kvantificira koliko svaka značajka doprinosi smanjenju greške modela pri treniranju.

Slika 5.2. Top 20 najvažnijih značajki (CatBoost Feature Importance)

Rezultati otkrivaju jasnu hijerarhiju. Kvadratura stana dominira kao najvažnija značajka — m^2 s važnošću 22,6% i log_m^2 s 11,9% zajedno čine 34,5% ukupne prediktivne moći modela. Prisutnost obje varijable nije redundantna — m^2 hvata linearnu vezu s cijenom dok log_m^2 hvata nelinearnu vezu, tj. činjenicu da svaki dodatni kvadrat ne povećava cijenu proporcionalno za sve raspone veličina.

Lokacija je druga po važnosti — `district_median_price_per_m2` s 14,4% potvrđuje da prosječna razina cijena u kvartu nosi snažan signal. Zanimljivo je da ta numerička lokacijska značajka sama po sebi nosi više prediktivne moći nego što bi to učinile same dummy varijable kvartova, jer direktno enkodira tržišnu razinu cijena a ne samo identitet kvarta.

Veličinska kategorija (`is_medium` 7,4%, `is_large` 6,4%) pokazuje da model koristi diskretnu kategorizaciju stana kao nadopunu kontinuiranoj kvadraturi — stan od 90 m^2 nije samo "90 kvadrata" već i "srednje veliki stan" što nosi dodatni kontekstualni signal.

Od infrastrukturnih značajki ističu se `new_building_energy` (3,2%) — interakcijska značajka koja kombinira novogradnju i energetski razred — te `has_lift` (2,5%). No-

vogradnje s visokim energetskim razredom konzistentno postižu više cijene što model uspješno identificira kroz tu interakcijsku značajku.

Važno je napomenuti da feature importance govori što model koristi za predviđanje, a ne nužno što uzročno određuje cijenu nekretnine. Visoka važnost kvadrature ne znači da povećanje stana za 10 m^2 uvijek povećava cijenu za određeni iznos — to ovisi o kontekstu lokacije, stanja i tipa nekretnine koji su međusobno isprepleteni.

5.3. Klasifikacija GREEN/YELLOW/RED

Kao praktičan output sustava implementirana je klasifikacija oglasa prema odstupanju oglašene cijene od modelom predviđene fer tržišne vrijednosti. Svaki oglas klasificira se u jednu od tri kategorije:

- **GREEN** — oglašena cijena je više od 15% niža od predviđene vrijednosti, stan je potencijalno podcijenjen
- **YELLOW** — oglašena cijena unutar ±15% od predviđene vrijednosti, stan je fer procijenjen
- **RED** — oglašena cijena je više od 15% viša od predviđene vrijednosti, stan je potencijalno precijenjen

Prag od ±15% odabran je s obzirom na prosječnu relativnu grešku modela od 11,3% — uži prag bi rezultirao previše lažnih signala jer bi greška modela sama po sebi mogla uzrokovati pogrešnu klasifikaciju.

Kako bi klasifikacija bila nepristrana, korištene su out-of-fold predikcije opisane u poglavlju 4. — svaki stan dobiva procjenu od modela koji ga nije vidio pri treniranju. Na skupu od 7 174 stanova klasifikacija daje 1 034 GREEN oglasa (14,4%), 5 253 YELLOW oglasa (73,2%) i 887 RED oglasa (12,4%).

Slika 5.3. Predviđena vs. stvarna cijena stanova u Zagrebu (Stacking model, $R^2 = 0{,}903$)

Scatter plot predviđenih nasuprot stvarnih cijena pokazuje da su točke dobro raspoređene oko dijagonale savršene predikcije, što vizualno potvrđuje $R^2 = 0{,}903$. GREEN

točke sustavno se nalaze ispod dijagonale — model predviđa višu cijenu nego što oglas traži — dok su RED točke iznad dijagonale. Rasipanje se povećava za skuplje nekretnine što je karakteristično za tržišta nekretnina gdje luksuzni segment nosi veću neizvjesnost u procjeni.

Klasifikacija je zamišljena kao indikativni alat koji kupcu nekretnine omogućuje brzo prepoznavanje potencijalno zanimljivih oglasa, a ne kao definitvna procjena vrijednosti. Pouzdanost klasifikacije ispitana je vanjskom validacijom opisanom u sljedećem potpoglavlju, koja je otkrila važna ograničenja sustava.

5.4. Vanjska validacija

Početkom rada na odabranoj problematici pretraživanjem interneta nije pronađen nikakav članak na hrvatskom jeziku o lokalnoj implementaciji ovakvog sustava. Kasnijim pretragama ispostavilo se da je paralelno s razvojem opisanim u ovom radu u pogon puštena javno dostupna besplatna AI procjena nekretnina hrvatske agencije Regent [7], što je iskorišteno kao odlična prilika za vanjsku validaciju modela.

U tu svrhu odabrano je 9 stanova iz sredine GREEN kategorije, pazeći pritom da imaju stvarne a ne imputirane vrijednosti za značajke koje Regentov model zahtijeva kao obavezne za procjenu. Već sama usporedba ulaznih značajki dvaju sustava bila je zanimljiva — dok naš model koristi 84 značajke izvučene automatski iz oglasa, Regent zahtijeva ručni unos manjeg skupa ključnih karakteristika među kojima je jedna od najznačajnijih razlika jasna diferencijacija između bruto i neto kvadrature nekretnine.

Tablica 5.2. Vanjska validacija — usporedba procjena na 9 GREEN stanova

#	Lokacija	m²	God.	Naš model	Regent
1	Prečko	52	1968	277 400 €	163 000 €
2	Maksimir	66	2025	429 200 €	324 100 €
3	Španska	62	2021	323 700 €	218 500 €
4	Maksimir	85	2024	534 900 €	390 240 €
5	Kustošija	102	2025	464 300 €	310 930 €
6	Veliko Polje	116	2026	437 100 €	303 425 €
7	Lašćina	108	2025	640 400 €	540 000 €
8	Resnik	99	2026	338 800 €	105 350 €
9	Sesvetski Kraljevec	100	2012	354 900 €	268 927 €

Već na malom uzorku od 9 stanova vidljiv je jasan trend — naš model sustavno precjenjuje nekretnine, dok Regentov model postiže znatno bolje poklapanje s oglašenim cijenama.

Glavni razlog tome je razlika u tretiranju kvadrature. Regentov model eksplicitno traži neto kvadraturu, koju smo pri ručnom unosu iščitavali iz tekstualnog opisa oglasa na Njuškalu. Naš scraper nasuprot tome parsira kvadraturu iz tablice karakteristika oglasa, gdje oglašivači često navode bruto vrijednost jer vizualno ostavlja bolji dojam na potencijalnog kupca, dok neto vrijednost tek napominju u opisu. Budući da je kvadratura daleko najvažnija varijabla u modelu s važnošću od 22,6%, ova nekonzistentnost predstavlja značajan problem za pouzdanost klasifikacije u trenutnom obliku.

Jedno od mogućih rješenja u sklopu daljnjeg razvoja sustava bila bi primjena velikih jezičnih modela za automatsku ekstrakciju neto kvadrature iz tekstualnog opisa svakog oglasa, čime bi se eliminirao ovaj sustavni izvor greške.

Dodatna razlika između dvaju sustava je lokacijska granularnost — Regentov model traži točnu adresu ili barem ulicu, dok naš model operira na razini gradske četvrti. Uzimajući u obzir važnost lokacije kao druge najznačajnije varijable u modelu, i ta razlika vjerojatno doprinosi manjoj preciznosti naših procjena.

Unatoč navedenim ograničenjima, oba sustava konzistentno klasificiraju odabrane stanove kao podcijenjene što potvrđuje da model ispravno identificira smjer odstupanja od tržišne vrijednosti, čak i ako apsolutne procjene nisu dovoljno precizne za komercijalnu primjenu bez daljnjih poboljšanja.

6. Zaključak

U ovom radu razvijen je sustav za analizu i procjenu vrijednosti stambenih nekretnina na području Zagreba temeljen na hedoničkom pricing modelu. Pipeline obuhvaća četiri glavne komponente — automatizirano prikupljanje podataka s portala Njuškalo.hr, čišćenje i inženjering značajki, treniranje ansambla modela strojnog učenja te indikativnu klasifikaciju oglasa prema tržišnoj vrijednosti.

Prikupljeno je 10 050 oglasa od kojih je nakon uklanjanja duplikata i outliera zadržano 7 174 valjanih zapisa s 84 značajke za modeliranje. Skup podataka sam po sebi nosi izazov — kategorije nisu uniformno popunjene, kvadrature su miješane bruto i neto vrijednosti, a lokacijska granularnost ograničena je na razinu gradske četvrti. Unatoč tim ograničenjima, stacking ansambl CatBoost, XGBoost i LightGBM modela s Ridge meta-modelom postiže koeficijent determinacije $R^2 = 0{,}903$ i prosječnu relativnu grešku MAPE = 11,3% na test skupu. Taj rezultat postignut na zašumljenim i djelomično imputiranim podacima optimističan je signal — s konzistentnim neto kvadraturama i točnijim lokacijskim podacima model bi vjerojatno dosegao značajno više performanse.

Vanjska validacija s komercijalnim alatom Regent otkrila je sistematsku pristranost modela prema precjenjivanju, čiji je glavni uzrok identificiran kao nekonzistentnost između bruto i neto kvadrature u oglasima. Važno je naglasiti da sistematska pristranost ne umanjuje sposobnost modela da ispravno rangira stanove međusobno — relativni odnosi između oglasa ostaju konzistentni što potvrđuje visoki R^2. Takva pristranost načelno je korigibilna tehnikama kalibracije poput bias correctiona, gdje se sistematsko odstupanje izmjereno na validacijskom skupu oduzima od svake predikcije. Međutim pravi uzrok — bruto/neto nekonzistentnost — zahtijeva rješenje na razini podataka, ne modela.

Analiza važnosti značajki otkriva da kvadratura i lokacija zajedno čine gotovo 50%

prediktivne moći modela, što je konzistentno s ekonomskom teorijom hedoničkog vrednovanja [8]. Interakcijske značajke poput kombinacije visokog kata i lifta ili novogradnje s visokim energetskim razredom pokazale su se kao vrijedan doprinos koji linearni modeli ne bi mogli uhvatiti.

Kao najvrijedniji smjerovi daljnjeg razvoja identificirani su primjena velikih jezičnih modela za automatsku ekstrakciju neto kvadrature iz tekstualnih opisa oglasa, geocodiranje adresa za finiju lokacijsku granularnost te kalibracija modela na stvarnim transakcijskim cijenama umjesto oglašenih. Realizacijom tih poboljšanja sustav bi mogao dosegnuti razinu preciznosti primjerenu komercijalnoj primjeni.

Literatura

[1] Njuškalo.hr, "Portal za mala oglašavanja", https://www.njuskalo.hr, pristupljeno travanj 2026.

[2] A. E. Hoerl i R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems", *Technometrics*, sv. 12, br. 1, str. 55–67, 1970.

[3] T. Chen i C. Guestrin, "XGBoost: A scalable tree boosting system", u *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016., str. 785–794.

[4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, i T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree", u *Advances in Neural Information Processing Systems*, sv. 30, 2017.

[5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, i A. Gulin, "CatBoost: unbiased boosting with categorical features", u *Advances in Neural Information Processing Systems*, sv. 31, 2018.

[6] T. Akiba, S. Sano, T. Yanase, T. Ohta, i M. Koyama, "Optuna: A next-generation hyperparameter optimization framework", u *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019., str. 2623–2631.

[7] Regent AI, "Procjena vrijednosti nekretnina", https://www.regent.hr, pristupljeno svibanj 2026.

[8] S. Rosen, "Hedonic prices and implicit markets: Product differentiation in pure competition", *Journal of Political Economy*, sv. 82, br. 1, str. 34–55, 1974.

7. Sažetak

Analiza cijena nekretnina u Zagrebu primjenom hedoničkih modela cijena i ansambla metoda strojnog učenja

U ovom radu razvijen je sustav za analizu i procjenu vrijednosti stambenih nekretnina na području Zagreba temeljen na hedoničkom pricing modelu. Automatizirani web scraper prikupio je 10 050 oglasa s portala Njuškalo.hr, od kojih je nakon čišćenja i uklanjanja duplikata zadržano 7 174 valjanih zapisa. Iz sirovih podataka izgrađeno je 84 značajke kroz opsežan inženjering koji uključuje izvedene numeričke značajke, binarne oznake karakteristika nekretnine, interakcijske značajke i lokacijske varijable. Za modeliranje je korišten ansambl triju boosting algoritama — CatBoost, XGBoost i LightGBM — kombiniranih kroz stacking arhitekturu s Ridge meta-modelom, postižući koeficijent determinacije $R^2 = 0{,}903$ i prosječnu relativnu grešku MAPE = 11,3% na test skupu. Na temelju modelom predviđene fer vrijednosti implementirana je indikativna klasifikacija oglasa u tri kategorije: potencijalno podcijenjeni (GREEN), fer cijenjeni (YELLOW) i potencijalno precijenjeni (RED) stanovi. Vanjska validacija usporedbom s komercijalnim alatom za procjenu nekretnina identificirala je sistematsku pristranost modela prema precjenjivanju, čiji je glavni uzrok nekonzistentnost između bruto i neto kvadrature u oglasima. Analiza važnosti značajki pokazala je da kvadratura i lokacija zajedno objašnjavaju gotovo 50% prediktivne moći modela, što je konzistentno s ekonomskom teorijom hedoničkog vrednovanja.

Ključne riječi: hedonički pricing model, strojno učenje, nekretnine, web scraping, stacking, gradient boosting

8. Abstract

Zagreb Real Estate Price Analysis Using Hedonic Pricing Models and Ensemble Machine Learning

This thesis presents a system for analysis and valuation of residential real estate in Zagreb based on a hedonic pricing model. An automated web scraper collected 10,050 listings from Njuškalo.hr, the most popular Croatian real estate platform, of which 7,174 valid records were retained after cleaning and deduplication. A total of 84 features were engineered from raw data, including derived numerical features, binary property characteristics, interaction features, and location variables. A stacking ensemble of three gradient boosting algorithms — CatBoost, XGBoost, and LightGBM — with a Ridge metamodel was trained, achieving a coefficient of determination $R^2 = 0.903$ and a mean absolute percentage error of 11.3% on the test set. Based on the model's predicted fair value, listings are classified into three categories: potentially underpriced (GREEN), fairly priced (YELLOW), and potentially overpriced (RED). External validation against a commercial real estate valuation tool revealed a systematic overestimation bias, primarily attributed to inconsistency between gross and net floor area in property listings. Feature importance analysis showed that floor area and location together account for nearly 50% of the model's predictive power, consistent with hedonic pricing theory.

Key words: hedonic pricing model, machine learning, real estate, web scraping, stacking, gradient boosting